

INTRODUCCIÓN A DATA WAREHOUSING – INGENIERÍA DE DATOS

Data Warehouse Northwind — Trabajo Práctico Grupal

Trabajo Práctico Grupal — Northwind


Integrantes: Carlos Aular, Juan Martín Pedrozo

Índice

0. Introducción	3
Decisiones más importantes	3
1. Adquisición	3
2. Modelado	6
3. Ingesta inicial	6
4. Actualización	6
5. Gestión de Calidad (DQM)	7
6. Gestión de Metadata	8
7. Gestión de Memoria	8
8. Gestión de Enriquecimiento	8
9. Publicación — Producto de Datos	9
10. Publicación — Tablero	9

0. Introducción

Trabajo Práctico Grupal 01 de Data Warehousing sobre Northwind, en 4 etapas (Adquisición, Ingeniería, Actualización, Publicación), implementadas como scripts SQL/Python ejecutados manualmente desde una TUI, con trazabilidad en tablas DQM y MET_.



Arquitectura de capas: TXT_ -> TMP_ -> DWA_/DWM_ -> DP0x_, con DQM_/MET_ transversales.

- **Prefijos de capa:** TXT_, TMP_, ING_, DWA_, DQM_, DWM_, MET_, DPxx_, uno por capa del pipeline.
- **Nombrado y TUI:** scripts e<etapa>p<paso>_<descripción>; la TUI agrupa por prefijo, colapsado por defecto, y ejecuta manualmente el script hoja seleccionado.

59 TABLAS REALES	11 TABLAS INGESTA1	4 CSV INGESTA2	2 TABLEROS HTML
---------------------	-----------------------	-------------------	--------------------


Decisiones más importantes

Síntesis de las decisiones de diseño con mayor impacto en el proyecto, tomadas a lo largo de las 4 etapas (detalle completo, con justificación y alternativas descartadas, en `DOCS/decisiones_de_diseno.md` e `informe_final_detallado.pdf`).

- **Convenciones de capa:** prefijos TXT_/TMP_/DWA_/DQM_/DWM_/MET_/DPxx_ para identificar cada capa, aplicados de forma consistente en las 59 tablas del proyecto.
- **Alcance del DER:** 3 tablas (customer_customer_demo, customer_demographics, us_states) quedan fuera por no tener CSV en Ingesta1.
- **Tolerancia cero en validación:** umbral_aplicado=0.0 en las 11 tablas de Ingesta1: cualquier error de formato/PK/FK bloquea la carga siguiente.
- **Grano del hecho:** línea de orden (dwa_fact_order_lines) con 6 dimensiones; freight se conserva no aditivo (order_freight_amount), no se prorratea.
- **DQM en 3 tablas por grano:** eventos/validaciones/perfilado, en vez de una EAV genérica que mezclaría preguntas distintas.
- **Corrección de dato en Ingesta2:** customerID "XXXXX" -> "OLDWO" en la orden 11078: se corrigió manualmente el dato de origen (la dirección de envío coincidía con ese cliente) y se documentó el criterio aplicado.
- **Historial SCD2:** capa de Memoria (dwm_customer_history/dwm_product_history) con vigente_desde/vigente_hasta/es_vigente.
- **Enriquecimiento externo:** world-data-2023 aporta 6 atributos geográficos a dwa_dim_geography; customer_score vive en tabla separada (dwa_enr_customer_score), no como columna nullable de la dimensión.
- **Producto de datos publicado:** dp01_ventas_geo_score con grano (año, mes, país de envío, segmento de score), pensado para consumo directo por tablero o Power BI.
- **Tableros HTML estáticos:** sin dependencias externas, para que la entrega sea reproducible sin depender de Power BI.
- **Tracking de scripts sin FK a DQM:** Scripts/ScriptVersions/ScriptRuns registran cada ejecución; DQM se referencia por nombre_script (TEXT) a propósito, para no atar ambos esquemas.
- **Claves surrogate + naturales:** GENERATED ALWAYS AS IDENTITY en dimensiones/hecho, con clave natural UNIQUE para trazabilidad hacia TMP_.


1. Adquisición

11 CSV de Ingesta1 analizados contra el DER de Northwind. Cada tabla pasa TXT_ (copia fiel) → validación de formato/PK (tolerancia cero) → TMP_ (tipada); la carga se bloquea si queda algún `ERROR`.



* categories / customers / employees tienen ajustes de columnas frente al DER -- ver detalle en el texto

DER de Northwind: tablas mantenidas vs. excluidas del alcance.



Flujo TXT_ -> validación -> TMP_ (con bloqueo).


- **Alcance del DER:** customer_customer_demo, customer_demographics y us_states quedan fuera: no tienen CSV en Ingesta1.
- **picture / photo:** se incluyen en TXT_ como hex, se excluyen en TMP_ (sin valor analítico).
- **Nulos y separador:** "NULL" string -> NULL real en la carga; customers.csv usa ';' (CRLF), manejado explícitamente.
- **Tipos con desvío del DER:** territory_id queda TEXT (preserva ceros a la izquierda); discontinued es INTEGER 0/1 (SQL estándar no tiene BOOLEAN); orders.freight es NUMERIC; reportsTo es INTEGER nullable (autorreferencia).
- **Carga CSV -> TXT_:** csv.DictReader + bulk insert SQLAlchemy (no COPY FROM: fuera del contrato de sesión de runner.py).

- **Umbral de aceptación:** tolerancia cero (umbral_aplicado=0.0) en las 11 tablas; TMP_ no declara FK físicas (staging), la integridad se valida aparte.

131 VALIDACIONES OK	0 REGISTROS AFECTADOS	18 CHEQUEOS FK_INTEGRIDAD
-------------------------------	---------------------------------	-------------------------------------

2. Modelado

Estrella de ventas, grano línea de orden: `dwa_fact_order_lines` (2155 filas) + 6 dimensiones (date, customer, product, employee, shipper, geography).



Modelo dimensional: hecho + 6 dimensiones.

- **freight en el hecho:** se conserva como `order_freight_amount`, no aditivo (no se prorratea entre líneas).
- **Dimensión geográfica:** básica en Etapa 2 desde Ingesta1; world-data-2023 se suma en Etapa 3.
- **Stock de producto:** `units_in_stock/units_on_order/reorder_level` y `stock_alarm_level` promovidos al DWA.
- **Claves:** surrogate GENERATED ALWAYS AS IDENTITY + clave natural UNIQUE para trazabilidad a TMP_.


3. Ingesta inicial

Carga inicial del DWA (`e2_p05_cargar_dwa_inicial`) desde TMP_ ya validada, con controles previos de integridad de joins, grano único y medidas no negativas.

2155 LÍNEAS DE HECHO	91 CLIENTES (DIM)	77 PRODUCTOS (DIM)	89 CLIENTES CON VENTAS
--------------------------------	-----------------------------	------------------------------	----------------------------------

4. Actualización

4 CSV de novedades (Ingesta2) siguen el mismo esquema TXT_ → TMP_ → validación, más integridad referencial contra TMP_ Ingesta1. Ingesta2 se considera la versión vigente más reciente (orden de prevalencia).




Ingesta2 -> SCD2 (DWM_) -> recálculo de enriquecimiento.

- **D1 — Corrección de dato:** customerID "XXXXX" -> "OLDWO" en la orden 11078 (la dirección de envío coincide con ese cliente de Ingesta1).
- **Historial SCD2:** 91 versiones de clientes, 77 de productos.

5. Gestión de Calidad (DQM)

DQM con 3 tablas por grano (no EAV genérica): evento de proceso, resultado de chequeo puntual, estadística descriptiva.



dqm_eventos / dqm_validaciones / dqm_perfilado y cuándo escribe cada una.

- **3 tablas por grano:** se descartó una EAV genérica: mezclaría granos distintos y dificultaría las consultas.
- **Sin FK a tracking:** DQM referencia nombre_script (TEXT), sin FK física a Scripts/ScriptVersions/ScriptRuns, a propósito.

131 VALIDACIONES	68 EVENTOS	256 COLUMNAS PERFILADAS
---------------------	---------------	----------------------------

6. Gestión de Metadata

Esta es la parte del proyecto que funciona como un **catálogo**: un lugar donde queda anotado qué tablas existen, qué significa cada columna, qué proceso las creó o las modifica, y qué reglas de calidad se les aplican. Sirve para que cualquiera del equipo (o quien evalúe el trabajo) entienda la estructura sin tener que leer todo el código. Hoy el catálogo tiene 35 entidades documentadas, 43 columnas descritas, 23 procesos registrados y 16 reglas de calidad definidas.

Un registro de qué se ejecutó y cuándo


Además del catálogo, cada vez que se corre un script queda anotado automáticamente: qué script fue, qué versión, cuándo empezó y terminó, y si salió bien o dio error. Es como un cuaderno de bitácora del trabajo hecho, que permite revisar el historial de ejecuciones o entender qué pasó ante un problema, sin depender de la memoria del equipo. Este registro técnico se guarda en tablas propias (`Scripts`, `ScriptVersions`, `ScriptRuns`), separadas de las tablas de calidad de datos, para no mezclar "qué se ejecutó" con "qué tan buenos son los datos".

7. Gestión de Memoria

Cuando cambia un dato importante de un cliente o un producto —por ejemplo, un cliente cambia de ciudad, o un producto cambia de categoría— el sistema no borra el dato anterior: guarda la versión vieja y agrega una nueva, marcando cuál es la vigente en cada momento. Así se puede reconstruir cómo era la información en el pasado, no solo cómo es hoy. Este historial se guarda para clientes y productos por separado: hoy hay 91 versiones registradas de clientes y 77 de productos.

8. Gestión de Enriquecimiento

Enriquecer los datos significa sumarle información de afuera que no viene de Northwind, para que los análisis sean más completos. En este proyecto se incorporaron dos fuentes externas: datos de países (capital, idioma, moneda y coordenadas geográficas) para poder ubicar las ventas en un mapa, y un puntaje de cliente (*customer score*) que indica qué tan valioso es cada cliente, para poder agrupar las ventas por ese puntaje en los tableros.



De los productos DP0x_ a los tableros HTML.

- **Datos de países:** se sumaron 6 atributos por país (código, capital, idioma, moneda, latitud y longitud), incluyendo un mapeo manual para los pocos países cuyo nombre no coincidía entre las dos fuentes.
- **Puntaje de cliente:** se guarda en su propia tabla en vez de como columna del cliente, porque es un dato externo y no todos los clientes tienen puntaje (83 de 91 lo tienen).
- **Métricas de venta:** solo se calculan para los clientes que efectivamente compraron algo, no para toda la base de clientes.

9. Publicación — Producto de Datos

D1: producto `dp01_ventas_geo_score`, grano (año, mes, país de envío, segmento de score).

470 FILAS	21 PAÍSES	830 ÓRDENES	\$1,265,793 VENTA NETA
---------------------	---------------------	-----------------------	----------------------------------

10. Publicación — Tablero

D2/D3: 2 tableros HTML estáticos (sin dependencias externas): `tablero_dp01_ventas_geo_score.html` (KPIs, top países, segmentos de score, evolución mensual) y `tablero_dp02_dqm.html` (validaciones, eventos, perfilado) alimentado por 3 tablas `dp02_dqm_*_resumen`.

Segmento	Órdenes	Venta neta
alto_4_5	130	177949.105
medio_2_3	479	829827.663
bajo_0_1	146	147941.629
sin_score	75	110074.6425