

El presente trabajo documenta la implementación de un Data Warehouse Analytics (DWA) construido sobre la base de datos Northwind, abarcando desde la ingesta inicial de datos hasta la generación de productos analíticos finales. El proyecto implementa una arquitectura de cinco capas diferenciadas que garantiza la trazabilidad completa del flujo de datos y la aplicación sistemática de controles de calidad.

Durante el desarrollo se procesaron dos ingestas de datos, implementando un framework de Data Quality Management (DQM) que detectó y gestionó distintos tipos de anomalías. El sistema resultante incluye un modelo dimensional optimizado, procesos automatizados de carga incremental y vistas analíticas diseñadas para soportar la toma de decisiones empresariales. Se adjunta el informe con los principales agregados.

1. Arquitectura del Sistema de Data Warehousing

1.1 Estructura de Capas Implementada

La arquitectura desarrollada se fundamenta en una de responsabilidades a través de cinco capas especializadas, cada una con objetivos específicos

Capa TMP (Temporal): Constituye el área de staging inicial donde se almacenan los datos crudos provenientes de los archivos CSV del modelo Northwind. Esta capa se caracteriza por dos decisiones arquitectónicas fundamentales:

1. **Carga de datos como VARCHAR:** La mayoría de los campos se cargan inicialmente como cadenas de texto para facilitar la transformación posterior y evitar pérdidas de información por conversiones automáticas erróneas.
2. **Preservación de identificadores:** Los campos ID se mantienen como VARCHAR(255) para evitar la pérdida de valores que inician con cero, un problema común en sistemas que realizan conversiones automáticas a tipos numéricos.

Capa STG (Staging): Funciona como la capa de preparación donde se ejecutan procesos de normalización y limpieza básica. Aquí se aplican las primeras transformaciones que estandarizan el formato de los datos sin alterar su esencia semántica.

Capa DWM (Data Warehouse Memory): Implementa la base el modelo dimensional con todas las reglas de negocio aplicadas desde staging sin flags adicionales ni agregaciones.

Capa DWA (Data Warehouse Analytics): Constituye la capa enriquecida donde se calculan métricas derivadas, indicadores de gestión y se añade valor analítico a los datos base.

Capa DP (Data Products): Contiene las vistas optimizadas (con distintas agregaciones) específicamente para el consumo analítico por parte de los usuarios finales y herramientas de Business Intelligence.

Además, para cada capa se realizaron los inputs en tablas DQM y Metadata, aunque sin un esquema separado.

1.2 Modelo Dimensional Implementado

El diseño dimensional resultante comprende un conjunto balanceado de dimensiones y una tabla de hechos central:

Dimensiones desarrolladas:

- DIM_Country
- DIM_Date
- DIM_Shipper
- DIM_Supplier
- DIM_Customer
- DIM_Employee
- DIM_Product


Tabla de Hechos:

- FACT_Sales

Esta estructura dimensional permite análisis multidimensionales eficientes y soporta diversos patrones de consulta analítica típicos en entornos empresariales.

Debajo se adjunta el DER de la tabla de DWA (ya enriquecida)

Imagen: Diagrama Entidad Relacion(DER) de la DWA



2. Framework de Gestión de Calidad de Datos

2.1 Arquitectura del Sistema DQM

El sistema de Data Quality Management implementado se basa en dos tablas centrales que proporcionan trazabilidad completa:

- **dqm_log**: Registro detallado de todos los controles de calidad ejecutados, incluyendo tipo de control, resultados obtenidos y acciones tomadas.
- **dqm_eventos**: Sistema de trazabilidad que documenta la evolución completa de cada proceso, desde su inicio hasta su finalización.

2.2 Controles Implementados y Resultados Obtenidos

Anomalías definidas para la capa STG:

Controles aplicados al momento de la ingestión desde archivos TMP a STG:

- **Campos nulos:** Validación de claves primarias y campos obligatorios (customerID, region, postcode, hireDate, companyName, etc.).
- **Normalización de texto:** Aplicación de formato title case, eliminación de espacios múltiples.
- **Estandarización de valores:** Unificación de variantes como "USA"/"UK" a "United States"/"United Kingdom".
- **Consistencia de fechas:**
 - birthDate > hireDate
 - orderDate > GETDATE(), requiredDate > GETDATE()
- **Rango etario:** Edad mínima requerida para empleados (≥ 16 años).
- **Freight negativo:** Validación en orders.
- **Valores no válidos:** Por ejemplo, fechas con el texto "NULL".
- **Registro de eventos DQM:** Cada inserción genera logs en dqm_eventos y hallazgos en dqm_log.

Validaciones aplicadas en la capa DWM:

- **Carga incremental:** Se insertan registros nuevos o con cambios detectados (comparación campo por campo).
 - Controles específicos por tabla:
- **DIM_Employee:** fechas inválidas (hireDate en el futuro, edad < 16).
- **DIM_Supplier, DIM_Customer, DIM_Shipper:** control de NULL en claves primarias.
- **Control de claves foráneas indirectas:** Match con DIM_Country para traer el continente.

Auditoría completa:

- Eventos de inicio, fin y error (dqm_eventos).
- Cambios y anomalías (dqm_log) con descripción y cantidad de registros afectados.

Aplicados al pasar de DWM a DWA:

- **Creación de estructura enriquecida:** claves foráneas explícitas, tipos y relaciones ajustadas.
- **Control de integridad referencial:**
 - Validación de FK en dimensiones (countryID, supplierID, productID, etc.).
 - Verificación de existencia previa en DIM_Country para Customer, Supplier, Employee.
- **Eventos de carga:**
 - Registro en dqm_eventos para cada tabla.
 - Logs de errores por claves foráneas no encontradas (dqm_log con tipo "FK no encontrada").

3. Procesamiento de Ingestas de Datos

3.1 Ingesta Inicial del Sistema

El proceso inaugural de carga procesó exitosamente:

- **11 archivos CSV** conteniendo datos maestros y transaccionales del modelo Northwind
- **1 archivo adicional** con datos geográficos (world-data-2023.csv) para enriquecimiento dimensional
- **Más de 10,000 registros** distribuidos a lo largo de todas las entidades del modelo

3.2 Ingesta Incremental y Validación

La segunda ingesta requirió lo siguiente:

Capacidades de procesamiento incremental:

- Operaciones MERGE automáticas para actualización de registros existentes
- Detección proactiva de violaciones de integridad referencial
- Mantenimiento automático de trazabilidad completa de cambios
- Actualización sincronizada de todas las capas enriquecidas

4. Enriquecimiento Analítico en la Capa DWA

4.1 Métricas Calculadas Implementadas

La capa DWA añade valor analítico sustancial mediante la generación de métricas derivadas y reduciendo la necesidad de procesamiento de tiempo de consulta, mas que nada para productos de datos posteriores o consultas por fuera de vistas públicas para equipos de BI.

Métricas financieras:

- **ventasBrutas:** Calculada como $\text{unitPrice} \times \text{quantity}$
- **ventasNetas:** Fórmula: $\text{ventasBrutas} \times (1 - \text{discount}) + \text{freight}$
- **descuentoMonto:** Valor absoluto del descuento aplicado

Indicadores operacionales:

- **flagDemorado:** Indicador binario para identificación de envíos tardíos
- **stockAlarma:** Sistema de alertas multinivel (0=Normal, 1=Bajo, 2=Agotado)
- **stockSobranate:** Identificación de productos discontinuados con inventario residual

5. Productos de Datos y Vistas Analíticas

5.1 Suite de Vistas Desarrolladas

Se implementaron seis vistas analíticas especializadas:

VentasPorPaisFecha: Análisis geográfico-temporal que permite identificar patrones de ventas por región y período, facilitando la planificación territorial y estacional.

StockCritico: Vista especializada en gestión de inventarios que identifica productos en riesgo de desabastecimiento, permitiendo acciones preventivas.

EnviosDemorados: Control de calidad del servicio logístico con identificación de patrones de retraso por transportista y ruta.

VentasPorEmpleado: Evaluación integral del desempeño comercial individual, incluyendo métricas de productividad y comparación peer-to-peer.

MayoresProveedores: Análisis de concentración de la cadena de suministro para identificar riesgos de dependencia y oportunidades de diversificación.

ResumenCalidadDatos: Vista de monitoreo continuo del sistema DQM para supervisión proactiva de la calidad del sistema.

- Este último no tendrá un DataProduct per sé.

5.2 Diseño Orientado al Usuario Final

Cada vista fue diseñada considerando casos de uso específicos del negocio, con filtros preconfigurados y agregaciones optimizadas que facilitan el consumo por parte de usuarios no técnicos. Principalmente se apuntaron a los KPIs de:

- Ventas (para los equipos de estrategia comercial) segmentados por, categorías, empleados y proveedores
- Ventas por país en base a los clientes.
- Stock (Para los equipos de Inventario entender donde estan las mayores oportunidades en el manejo de productos).

6. Sistema de Trazabilidad y Eventos

6.1 Registro Automático de Procesos

El sistema implementa un mecanismo robusto de logging que captura automáticamente:

- **Timestamps de inicio y finalización** de cada proceso
- **Contadores de registros procesados** por operación
- **Estados de ejecución** categorizados (EN_PROCESO, EXITOSO, ERROR)
- **Duración en segundos** para análisis de rendimiento
- **Usuario responsable** de cada ejecución para auditoría

6.2 Flujos de Eventos Típicos

Los patrones de eventos más comunes observados incluyen:

INICIO_CARGA → INSERCIÓN → FIN_CARGA (exitoso)

INICIO_CARGA → ERROR_VALIDACION → RECHAZO_PREVENTIVO (con error controlado)

Este sistema de eventos permite no solo la resolución rápida de problemas, sino también el análisis de tendencias operacionales y la optimización continua de procesos.

7. Gestión de Memoria Institucional

7.1 Estrategia de Preservación de Información

Aunque el modelo DWM no incluye tablas de histórico completo (_HIST), el sistema mantiene memoria institucional robusta mediante:

Estrategias de preservación:

- **Logs detallados en DQM** que documentan todos los cambios realizados
- **Procesos MERGE inteligentes** que actualizan registros preservando trazabilidad
- **Auditoría completa** de operaciones con identificación de usuarios y timestamps

Entendemos como mejora importante al trabajo presentado la re-implementación del DWM correspondiente.

7.2 Valor de la Memoria Institucional

Esta aproximación permite tanto la investigación de problemas históricos como el aprendizaje organizacional continuo, elementos críticos para la madurez del sistema de datos.

8. Métricas de Rendimiento del Proyecto

8.1 Volumen de Datos Procesados

- **Ingesta inicial:** >10,000 registros procesados exitosamente
- **Ingesta incremental:** 45 registros nuevos/actualizados
- **Tasa de rechazo por calidad:** <1% del volumen total

8.2 Cobertura de Calidad Implementada

- **Controles de calidad:** 15+ tipos diferentes implementados
- **Entidades monitoreadas:** 100% de cobertura
- **Procesos con trazabilidad:** 100% de cobertura completa

8.3 Disponibilidad de Información

- **Vistas analíticas:** 6 implementadas y optimizadas

- **Métricas de negocio:** 8 calculadas automáticamente
- **Dimensiones completas:** 7 totalmente operativas

9. Framework de Metadata y Documentación

9.1 Arquitectura de Metadata

Se desarrolló un sistema integral de documentación que garantiza la comprensibilidad y mantenibilidad del sistema a largo plazo. La metadata incluye definiciones precisas de cada campo, reglas de transformación aplicadas y linaje completo desde el origen hasta los productos finales.

9.2 Metadata Especializada por Capa

- **Capa TMP:** Documentación completa de la estructura cruda de archivos CSV, incluyendo tipos de datos originales y decisiones de carga iniciales.
- **Capa STG:** Mapeo entre nombres de campos originales y normalizados, y reglas de limpieza.
- **Capa DWM:** Documentación del modelo dimensional, incluyendo claves naturales, subrogadas y reglas de negocio aplicadas.
- **Capa DWA:** Fórmulas exactas para métricas calculadas y criterios para indicadores de gestión.
- **Capa DP:** Propósito de negocio de cada vista y sus capos, filtros aplicados y casos de uso recomendados.

9.3 Estándares y Glosario

Se establecieron convenciones de nomenclatura consistentes y un glosario integral que resuelve ambigüedades comunes, particularmente importantes cuando múltiples tablas contienen campos con nombres similares pero significados diferentes.

10. Desarrollo de Capacidades de Visualización

10.1 Estrategia de Tableros Analíticos

Con base en los productos de datos desarrollados, se diseñó una suite de tableros interactivos que transforman los datos del DWA en insights accionables para diferentes audiencias empresariales.



10.2 Tableros Implementados


El tablero de indicadores comerciales se compone de tres hojas principales.

La primera, enfocada en ventas netas, ofrece una visión completa del desempeño comercial, mostrando quiénes son los empleados más efectivos, cuáles son las categorías más vendidas, cómo se distribuyen las ventas y órdenes por proveedor, y cómo evolucionaron las ventas en el tiempo.

La segunda hoja analiza el stock disponible, detallando las unidades por categoría, los productos con mayor cantidad en inventario, y señalando aquellas categorías con mayores demoras o alertas por bajo nivel de stock.

Finalmente, la hoja de KPIs por país permite evaluar el rendimiento comercial desde una perspectiva geográfica, identificando los países y continentes con mayor cantidad de órdenes y ventas, y visualizando de forma clara dónde se concentran las operaciones y posibles demoras.





11. Aprendizajes Clave

11.1 Valor de la Arquitectura por Capas

La implementación confirmó la importancia crítica de una arquitectura de capas bien diferenciadas. Esta estructura no solo preserva el progreso del trabajo, sino que facilita significativamente el debugging y la evolución incremental del sistema. Durante el desarrollo, cuando surgieron problemas en las transformaciones, la separación clara permitió identificar rápidamente el origen sin rehacer trabajo previo.

11.2 Importancia del Contexto de Negocio

Un aprendizaje fundamental fue la necesidad de tratar los datos considerando su contexto empresarial real, no solo su representación técnica. La decisión de cargar IDs como VARCHAR, aunque contraintuitiva técnicamente, resultó crucial para preservar información valiosa como códigos postales con ceros iniciales.

11.3 Exploración como Base del Diseño

El proceso de exploración exhaustiva previo al diseño del DWA resultó una inversión invaluable. El análisis preliminar reveló patrones, anomalías y relaciones no evidentes en la documentación original, permitiendo diseñar transformaciones más efectivas y anticipar problemas de calidad.

11.4 Enfoque Product-Centric

La importancia de visualizar el producto final desde las etapas iniciales influyó significativamente en las decisiones de diseño dimensional. Este enfoque "backward design" garantizó que cada capa contribuyera directamente a generar valor analítico.

11.5 Metadata como Activo Estratégico

La experiencia destacó la importancia crítica de la documentación estructurada. La metadata bien desarrollada se convierte en un activo institucional que trasciende el proyecto individual, facilitando la incorporación de nuevos desarrolladores y la expansión de funcionalidades.

Conclusiones

El sistema desarrollado permite la carga y subida de nuevos archivos desde distintas fuentes, con algunas estandarizaciones. Se presentan oportunidades en cuanto al DWM dado que se realizan updates y las informaciones netas quedan en STG. Al tener los .csv sin embargo, pueden hacerse las actualizaciones correspondientes.

La experiencia adquirida durante esta implementación proporciona un framework reproducible para futuros desarrollos de data warehousing.

SOLO UTILIZAR COMO EJEMPLO